

トピックモデルによる 分散表現の獲得手法の提案

野沢 健人 若林 啓 (筑波大学)

単語の分散表現

- 単語を密なベクトル空間の1点として表現
- 単語間の演算が可能 ($\text{king} - \text{man} + \text{woman} = \text{queen}$)




図1：2次元空間における分散表現の例

次元を特徴付ける単語を獲得できれば表現はよりリッチに

既存研究

分散表現の獲得モデル

- ニューラルネットワークによる予測モデル
- 共起行列と行列分解に基づくモデル

分散表現の解釈 [Faruqui+, 2015]

- 高次元で疎ベクトルに変換
- 特徴量として解釈しやすい

研究目的

1. トピックモデルによる単語の分散表現の獲得
 - 単語を確率分布とベクトルとして扱う
2. 単語ベクトルとトピックの関係性の確認
 - 単語を確率値で表現しているため解釈しやすい

提案手法における分散表現獲得の流れ

1. 文書データの読み込み
2. 単語タイプを共起する単語の多重集合で表現
3. 1多重集合を1文書とみなし, LDAを学習
4. 単語のトピック分布とトピックの単語分布を出力

単語タイプを共起する単語の多重集合で表現

1 単語タイプをその前後 n 単語からなる多重集合で表現

文書1: 青森 の アップル ジュース は おいしい

文書2: オラクル と アップル は アメリカ の 企業 だ

文書3: [山梨 の ぶどう ジュース は 飲み やすい]



アップル = [青森, の, ジュース, は, オラクル, と, は, アメリカ]

例：前後2単語の場合

単語タイプを共起する単語の多重集合で表現

分布仮説から似た単語は似た多重集合になりやすい

文書1: 青森 の アップル ジュース は おいしい

文書2: オラクル と アップル は アメリカ の 企業 だ

文書3:[山梨 の ぶどう ジュース は 飲み やすい]



アップル = [青森, の, ジュース, は, オラクル, と, は, アメリカ]

ぶどう = [山梨, の, ジュース, は]

例：前後2単語の場合

Latent Dirichlet Allocation

- 文書の確率的生成モデル [Blei+, 2003]
- 文書内の単語の共起情報からトピックを発見
 - トピックで条件づけられる全単語の確率分布
 - 文書の単語で条件づけられるトピックの確率分布

機械学習


機械学習とは、人工知能における研究課題の一つで、人間が自然に行っている学習能力と同様の機能をコンピュータで実現...

文書データ

研究	0.05
課題	0.04
知識	0.03
科学者	0.02
...	

機械学習	0.04
人工知能	0.02
モデル	0.01
サンプル	0.01
...	

トピック



LDAの学習（トピック数3の場合）

多重集合で表現した1単語を1文書とみなし，LDAを学習

- 例：**アップル** = [青森, の, ジュース, は, オラクル, と, は, アメリカ]

1. 単語（多重集合）ごとのトピックの多項分布

- 確率分布とベクトルとして扱う

例：**アップル** = [0.3, 0.6, 0.1], **オラクル** = [0.6, 0.1, 0.3], **ぶどう** = [0.1, 0.7, 0.2]

2. トピックごとの単語の多項分布

例：トピック1 = [ソフトウェア:0.3, PC:0.2, プログラム:0.1, ...]

トピック2 = [ジュース:0.4, パイ:0.2, フルーツ:0.1, ...]

トピック3 = [が:0.2, の:0.2, に:0.1, ...]

次元の解釈

- 単語のトピック分布の値が高いほど、そのトピックをもつ

例：**アップル** = [0.3, 0.6, 0.1]

トピックの単語分布の値が高いほど、トピックを特徴付ける単語

トピック1 = [ソフトウェア:0.3, PC:0.2, プログラム:0.1, ...]

トピック2 = [ジュース:0.4, パイ:0.2, フルーツ:0.1, ...]

トピック3 = [が:0.2, の:0.2, に:0.1, ...]

アップルはジュース, パイ, フルーツなどの単語で特徴付けられる

ぶどう = [0.1, 0.7, 0.2]も同様のトピックで特徴付けられる

ぶどうは、トピック2の意味で**アップル**と類似

提案手法のまとめ

- 単語タイプを周囲 n 単語からなる多重集合とみなす
- 単語タイプのトピックの確率分布をベクトルとして獲得
- トピックから単語タイプを特徴付ける単語を抽出可能

実験

学習データと前処理

学習データ

2010年の英語版*Wikipedia*の本文記事の1/3

以下の前処理の結果112,635単語タイプを使用

前処理

- 頻度が100以上の単語のみを使用
- 非英数字は削除
- 数字は対応する英単語に変換
- 高頻度語のサブサンプリング [Mikilov+, 2013]

LDAの学習アルゴリズムとパラメータ

確率的変分ベイズ法を用いた学習アルゴリズム

- 確率的勾配法に基づく学習[Mimno+, 12]
- 1回の反復計算で一部の文書だけを用いる

ディリクレ分布のパラメータ α の学習の有無も実験

- α を学習するとトピックのまとまりがよくなる

分散表現の評価方法

評価方法

- word similarity : 順位相関係数による評価
 - *apple tree 0.2*
 - *apple orange 0.7*
- analogy : 正解率による評価
 - *man king woman queen*

比較手法

CBoWとSkip-gram [Mikolov+, 2013]

比較実験の結果

- word similarityでは約0.2~0.3の差
- analogyでは約0.4~0.5の差

	word similarity						analogy	
dataset	WS	WSS	WSR	MEN	MT	RW	Google	MSR
CBoW	0.703	0.770	0.656	0.726	0.655	0.484	0.553	0.585
Skip-gram	0.702	0.771	0.683	0.739	0.660	0.461	0.642	0.541
提案法 + cos	0.408	0.506	0.364	0.464	0.465	0.265	0.226	0.053
提案法 + js	0.437	0.563	0.377	0.508	0.516	0.266	-	-

表1：比較実験の結果

cos: コサイン類似度

js: ジェンセンシャノンダイバージェンス

トピックの解釈：python

- pythonのトピックの確率値 θ の高い上位3トピックに注目
- それぞれのトピックのうち確率値の高い上位10単語
 - 880：蛇と「Monty Python」
 - 145：プログラミング
 - 732：高頻度語

topic ID	880	145	732
θ	0.187	0.116	0.074
α	0.019	0.071	1.127
1	circus	archive	the
2	snake	software	i
3	monty	web	it
4	cobra	programming	you
5	sketch	database	be
6	palin	based	have
7	lizard	video	a
8	evening	server	but
9	grail	linux	if
10	viper	interface	can

トピックの解釈：bow

- bowのトピックで $\alpha < 0.2$ かつ確率値 θ の高い上位3トピックに注目
- それぞれのトピックのうち確率値の高い上位10単語
 - 389：船，装備など
 - 547：船
 - 919：衣服や体の部位

topic ID	389	547	919
θ	0.028	0.021	0.021
α	0.116	0.060	0.044
1	aircraft	ship	face
2	speed	ships	worn
3	weight	merchant	cap
4	gun	patrol	shoes
5	built	boats	wears
6	ship	naval	tie
7	machine	vessels	wore
8	power	crew	wear
9	drive	cargo	shirt
10	steam	vessel	shoulder

まとめ

LDAによる分散表現の獲得手法

- 確率分布をベクトルとみなす
 - ベクトルとして扱うことは、本評価では不向き
 - 確率分布で加算減算に相当する操作が必要
- ベクトルの次元とトピックが対応
 - 語義に近いトピックの獲得
 - Word Sense Inductionへの応用