


トピックモデルに基づく 大規模ネットワークの重複コミュニティ発見

野沢 健人 若林 啓 (筑波大学)

大規模グラフ

- ソーシャルグラフ
- ウェブグラフ
- オンラインショップの共購買グラフ




グラフをより小さい単位で扱いたい

グラフのコミュニティ

コミュニティ内部のノード間で強く結びつき、
外部とは弱く結びつく部分グラフ

性質の似たノードでまとめることができる

- 現実世界のグループ
 - 関連商品群
- などに対応




重複コミュニティ

1つのノードが複数のコミュニティに所属

現実のグラフで多く存在

– 前職の同僚と現職の同僚



既存研究

望ましい指標を最大化するグラフ分割

- ModularityやTriangle participation ratio
- 並列計算で高速化
 - 大量の計算機資源を要するため計算コストが高い


確率モデルによるグラフ構造のモデル化

LDAをグラフに適用

- 文書データに対するアルゴリズムをグラフに応用

文書とグラフの対応関係

- 1ノードは1文書に相当
- 距離1以下のノードは単語に相当



ノード (文書)	距離1以下のノード (単語)
A	A, B, C, D, E, x, y, z
B	B, A, E
C	C, D, E, A
D	D, E, C, A
E	E, B, A, C, D
x	x, y, A, w
y	y, A, x, z
z	z, y, A
w	w, x

Latent Dirichlet Allocation

- 文書の確率的生成モデル
- 文書内の単語の共起情報からトピックを発見
- 単語は各トピックの条件付き確率で表現

機械学習
機械学習とは、人工知能における研究課題の一つで、人間が自然に行っている学習能力と同様の機能をコンピュータで実現しようとする技術・手法のことである。

文書データ

研究	0.05
課題	0.04
知識	0.03
科学者	0.02
...	

機械学習	0.04
人工知能	0.02
モデル	0.01
サンプル	0.01
...	

トピック

LDAをグラフに適用

トピックをコミュニティと定義
各ノードのコミュニティの所属度合いを確率値で表現

ノード	距離1以下のノード
A	A, B, C, D, E, x, y, z
B	B, A, E
C	C, D, E, A
D	D, E, C, A
E	E, B, A, C, D
x	x, y, A, w
y	y, A, x, z
z	z, y, A
w	w, x

x, y, z, Aが高確率で
属するコミュニティ

x	0.22	E	0.20
y	0.22	C	0.20
z	0.20	D	0.18
A	0.15	B	0.18
w	0.07	A	0.12
C	0.05	x	0.04
D	0.04	y	0.03
B	0.04	z	0.03
E	0.01	w	0.02

コミュニティ

従来法におけるLDAの学習

周辺化ギブスサンプリングや変分ベイズ法による学習

1. **全ノード**について十分統計量の期待値を求める
2. パラメータの更新

1.と2.を繰り返す

実行時間は全ノード数に比例

ノード	距離1以下のノード
A	A, B, C, D, E, x, y, z
B	B, A, E
C	C, D, E, A
D	D, E, C, A
E	E, B, A, C, D
x	x, y, A, w
y	y, A, x, z
z	z, y, A
w	w, x

確率的変分ベイズ法による学習

確率的勾配法に基づく学習アルゴリズム[Mimno12]

- 1回の反復計算で**サンプルしたノード**だけ使用
- サンプルするノード数を**バッチサイズ**と呼ぶ

バッチサイズ4の場合

ノード	距離1以下のノード
B	B, A, E
C	C, D, E, A
z	z, y, A
w	w, x

サンプル



ノード	距離1以下のノード
A	A, B, C, D, E, x, y, z
B	B, A, E
C	C, D, E, A
D	D, E, C, A
E	E, B, A, C, D
x	x, y, A, w
y	y, A, x, z
z	z, y, A
w	w, x

確率的変分ベイズ法の1回目の計算

バッチサイズ4の場合

ノード	距離1以下のノード
B	B, A, E
C	C, D, E, A
z	z, y, A
w	w, x

← サンプル

ノード	距離1以下のノード
A	A, B, C, D, E, x, y, z
B	B, A, E
C	C, D, E, A
D	D, E, C, A
E	E, B, A, C, D
x	x, y, A, w
y	y, A, x, z
z	z, y, A
w	w, x

4ノードを使ってパラメータを更新

確率的変分ベイズ法の2回目の計算

バッチサイズ4の場合

ノード	距離1以下のノード
A	A, B, C, D, E, x, y, z
E	E, B, A, C, D
x	x, y, A, w
w	w, x

← サンプル

ノード	距離1以下のノード
A	A, B, C, D, E, x, y, z
B	B, A, E
C	C, D, E, A
D	D, E, C, A
E	E, B, A, C, D
x	x, y, A, w
y	y, A, x, z
z	z, y, A
w	w, x

4ノードを使ってパラメータを更新

提案手法の特徴

LDAによる高速な重複コミュニティ発見

- 確率的勾配法に基づく学習アルゴリズム
 - グラフをメモリに展開せず実行可能
 - コミュニティに所属するノードを確率値で表現
 - 1台の計算機で実行可能
- 実行時間と発見精度のトレードオフを調節可能
 - 実行時間はバッチサイズと反復回数に比例

評価実験

グラフの規模に対するスケーラビリティの評価


- コミュニティ発見の実行時間

重複コミュニティ発見精度の評価

- Triangle participation ratio (TPR)
 - コミュニティのノードが3角形に属する割合
 - 高いほどよいコミュニティ
- Conductance
 - コミュニティ外のノードとリンクするエッジの割合
 - 低いほどよいコミュニティ

トピックモデルで発見した コミュニティの評価方法

- トピックモデルはノードの所属確率を求める
- コミュニティに所属するノードを決定して比較




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

E	0.20
C	0.20
D	0.18
B	0.18
A	0.12
x	0.04
y	0.03
z	0.03
w	0.02

コミュニティ決定の流れ


1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用



x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 0/3 = 0.00$$

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 4/4 = 1.00$$

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 4/5 = 0.80$$

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 4/6 = 0.67$$

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 6/7 = 0.86$$

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 6/8 = 0.75$$

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用




x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 8/9 = 0.89$$

コミュニティ決定の流れ

1. 1つのコミュニティのノードを確率値の降順にソート
2. 確率順にTPRを計算
3. TPRが最大のコミュニティを使用
 $\{x, y, z, A\}$ がコミュニティに属する



x	0.22
y	0.22
z	0.20
A	0.15
w	0.07
C	0.05
D	0.04
B	0.04
E	0.01

$$\text{TPR} = 4/4 = 1.00$$

比較手法

- Clique percolation method (CFinder)
 - k -クリークをもとにコミュニティ発見
- SVINET
 - 確率モデルによるグラフ構造のモデル化
- Sparse LDA[Yao, 2009] (SLDA)
 - 周辺化ギブスサンプリングによる学習の実装を工夫
 - 1回の計算で全ノードを使用
- 提案法 (SVBLDA)
 - 確率的変分ベイズ法による学習
 - 1回の計算でサンプルしたノードを使用

実験データ


グラフ名	ノード数	エッジ数
DBLP	317,080	1,049,866
Orkut	3,072,441	117,185,083
Friendster	65,608,366	1,806,067,135

SNAP Datasets のグラフデータを使用

- Friendsterはデータベース(MySQL)に格納
- バッチサイズ分だけ適宜サンプル

実行時間の比較



提案法は比較手法と比べて大幅に高速化
データベースにアクセスしても高速



DBLPに対する コミュニティ発見精度の比較

既存手法と比較してやや劣る程度

ただし，提案法は性能向上の傾向が見られる





コミュニティ数 : 4000

反復回数 : 1000

バッチサイズ : 2000



バッチサイズを増減と発見精度

- バッチサイズは期待値計算に使うノード数
- TPRはバッチサイズの増加で中央値が1に接近
- Conductanceは箱の長さ・下ひげが伸びる



反復回数が増減と発見精度



- 反復回数は期待値の計算回数
- 2,000回以上では変化が小さい



学習時間の変化

反復回数が20,000回では約20時間必要

Sparse LDAと同等の学習時間だが発見精度は劣る
大規模グラフであれば提案法を使用



まとめ

- 高速なLDAの学習アルゴリズムによる大規模グラフのコミュニティ発見
 - 6000万ノード18億エッジを2時間弱で実行可能
- 発見精度と実行時間のトレードオフ
 - バッチサイズや反復回数で調節可能
 - メモリや実行時間に応じてSparse LDAの使用も